Politecnico di Torino

Assignment 1:

Ottimizzazione e simulazione in in condizioni di incertezza

Analisi di impatto delle incertezze in un modello Newsvendor tramite simulazione Monte Carlo

Realizzato da:

Bressan Sonia

Gambuzza Alessia

Data di stesura: Lunedì 4 maggio

1 Introduzione

L'obiettivo di questo report è valutare l'impatto dell'informazione perfetta rispetto alle condizioni reali, misurando quanto la carenza di dati penalizzi le performance del modello.

Abbiamo strutturato il nostro lavoro analizzando quattro scenari specifici:

- **Nella prima parte (Scenario 1)**, ci siamo concentrate sull'incertezza legata alla domanda primaria. Abbiamo studiato quanti giorni di storico vendite sono effettivamente necessari affinché le stime campionarie diventino sufficientemente accurate da permetterci di ordinare quantità quasi perfette.
- **Nella seconda parte (Scenario 2)**, abbiamo aggiunto un ulteriore livello di complessità tipico delle dinamiche commerciali reali: l'incertezza sul valore di recupero. Abbiamo simulato un contesto in cui la domanda è ben conosciuta, ma non sappiamo con certezza a quale percentuale del costo iniziale riusciremo a liquidare la merce invenduta.
- **Nella terza parte (Scenario 3)**, abbiamo esplorato come si comporta il modello quando i costi legati all'invenduto e quelli associati alle mancate vendite sono fortemente sbilanciati.
- **Nella quarta parte (Scenario 4)**, ci siamo concentrate sull'impatto della variabilità intrinseca del mercato. Abbiamo analizzato come una forte fluttuazione della domanda influisca sull'efficienza finale, dimostrando come un mercato molto turbolento diventi distruttivo per i profitti soprattutto quando mancano dati storici sufficienti per affrontarlo (confrontando un contesto quasi cieco di 10 giorni con uno solido di 250).

1.1 Modello teorico e metodo di simulazione

Per misurare le nostre performance, abbiamo prima dovuto definire analiticamente l'obiettivo perfetto a cui puntare.

Conoscendo quanto ci costa perdere una vendita ($c_u = p - c$) e quanto ci costa la merce invenduta ($c_o = c - r$), il modello stabilisce la probabilità ottimale di non esaurire le scorte (il quantile critico z):

$$z = \Phi^{-1}\left(\frac{c_u}{c_u + c_o}\right) \tag{1}$$

Traslando questo quantile sulla distribuzione reale della domanda, otteniamo la quantità teoricamente perfetta da ordinare (Q^*):

$$Q^* = \mu + \sigma \cdot z \tag{2}$$

Il profitto atteso teorico, che rappresenta il nostro traguardo del 100% di efficienza, viene calcolato utilizzando la funzione di perdita standardizzata $L(z) = \phi(z) - z(1 - \Phi(z))$:

$$\mathbb{E}[\Pi] = c_u\mu - c_o(Q^* - \mu) - (c_u + c_o)\sigma \cdot L(z) \tag{3}$$

Nella fase di simulazione il profitto per ogni singola iterazione è stato calcolato applicando la logica empirica del guadagno sulle vendite effettive e del pagare pegno per la merce

avanzata.

$$\Pi_{ottenuto} = c_u \min(Q, D) - c_o \max(0, Q - D) \tag{4}$$

dove D è la domanda reale simulata dal mercato e Q è la quantità che abbiamo deciso di ordinare basandoci solo sulle stime imperfette dei nostri dati storici (μ_{camp} e σ_{camp}).

Dal punto di vista operativo, la simulazione calcola per ogni singola iterazione sia il profitto massimo ottenibile a informazione perfetta 3, sia quello reale conseguito sulla base delle stime campionarie 4. Il confronto sistematico tra questi due valori permette di normalizzare i risultati e ricavare l'efficienza del sistema.

Per garantire la significatività statistica di tale analisi, questo processo è stato inserito all'interno di una simulazione Monte Carlo: ogni scenario è stato valutato su un orizzonte di 10.000 giorni di vendita e ripetuto per 1.000 iterazioni indipendenti per avere robustezza delle stime e convergenza dei parametri di efficienza.

2 Analisi dei risultati per il primo scenario

2.1 Impostazione del problema

In questa prima parte abbiamo voluto isolare il problema dell'incertezza sulla domanda. Abbiamo immaginato un prodotto la cui domanda reale segue una distribuzione normale con media (μ) pari a 500 e deviazione standard (σ) pari a 120.

A livello economico, abbiamo impostato i seguenti parametri:

- Costo di acquisto: 40
- Prezzo di vendita: 90
- Valore di recupero (svendita dell'invenduto): 15

Da questi dati abbiamo calcolato i nostri margini di rischio. Se ordiniamo un pezzo in meno del necessario, perdiamo un potenziale guadagno di 50 (*Costo di underage,* C_u). Se invece ordiniamo un pezzo di troppo, ci rimettiamo 25 (*Costo di overage,* C_o). Conoscendo perfettamente questi dati, potremmo calcolare la quantità ottima teorica e il profitto massimo raggiungibile.

Nella realtà, però, non conosciamo la vera media e varianza della domanda, ma dobbiamo stimarle. Nel nostro script, abbiamo fatto variare i giorni di osservazione (il nostro "storico dati") da 5 a 500. Per ogni ampiezza temporale abbiamo simulato l'estrazione di un campione di vendite passate per calcolare la media e la deviazione standard campionaria. Basandoci su queste stime, abbiamo ricalcolato la quantità da ordinare e abbiamo testato questa decisione su 10.000 giorni di vendita, calcolando l'efficienza del profitto rispetto all'ottimo teorico.

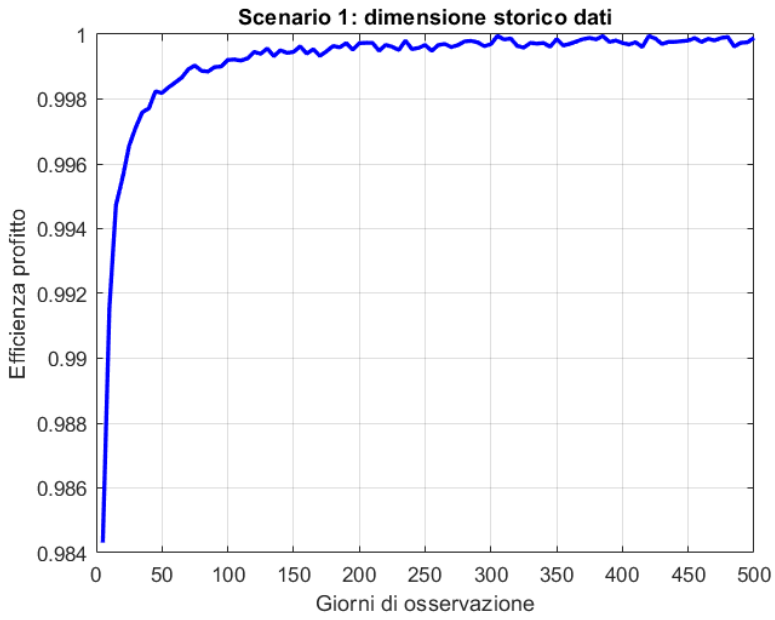


Figura 1: Efficienza del profitto in funzione dei giorni di osservazione della domanda.

Guardando il grafico prodotto dalla simulazione, si notano due fasi ben distinte:

- **Fase di grande incertezza (5-50 giorni)**: Quando abbiamo a disposizione pochissimi dati, la curva è molto bassa e instabile. Questo significa che stiamo calcolando medie e varianze sbagliate a causa del campione troppo piccolo, portandoci a ordinare quantità errate e a perdere molti margini di profitto.
- **Fase di convergenza (oltre i 100 giorni)**: Mano a mano che accumuliamo giorni di storico, l'efficienza sale rapidamente e si appiattisce verso il valore di 1 (cioè il 100% dell'efficienza). Il grafico ci dimostra che bastano circa 100-150 giorni di dati per avere stime così buone da garantire un profitto quasi identico a quello teorico perfetto.

3 Analisi dei risultati per il secondo scenario

3.1 Impostazione del problema

Nel secondo scenario la situazione è un po' diversa. Questa volta abbiamo supposto di conoscere già molto bene la domanda, fissando uno storico solido di 250 giorni. Il problema si sposta sulla fine della stagione di vendita: non sappiamo esattamente a quanto riusciremo a svendere i prodotti avanzati.

Abbiamo alzato il prezzo di vendita a 120 (quindi il C_u sale a 80) e abbiamo impostato il tasso di recupero reale in modo che vari casualmente tra il 30% e il 90% del costo di acquisto.

Nel codice, abbiamo fatto variare i giorni in cui osserviamo i prezzi delle vecchie svendite da 5 a 200. Il processo logico seguito è il seguente:

1. Attraverso una funzione dedicata, abbiamo calcolato la media campionaria di questo tasso di recupero.

2. Abbiamo usato questo valore stimato per aggiornare il costo dell'invenduto (C_o) e ricalcolare la quantità da ordinare.

3. Infine, abbiamo simulato le vendite considerando che ogni giorno il prezzo di svendita oscilla casualmente all'interno di quel range.

Questa impostazione ci permette di valutare quanto l'incertezza sul valore residuo della merce influisca sul profitto finale, pur avendo una stima della domanda molto precisa.

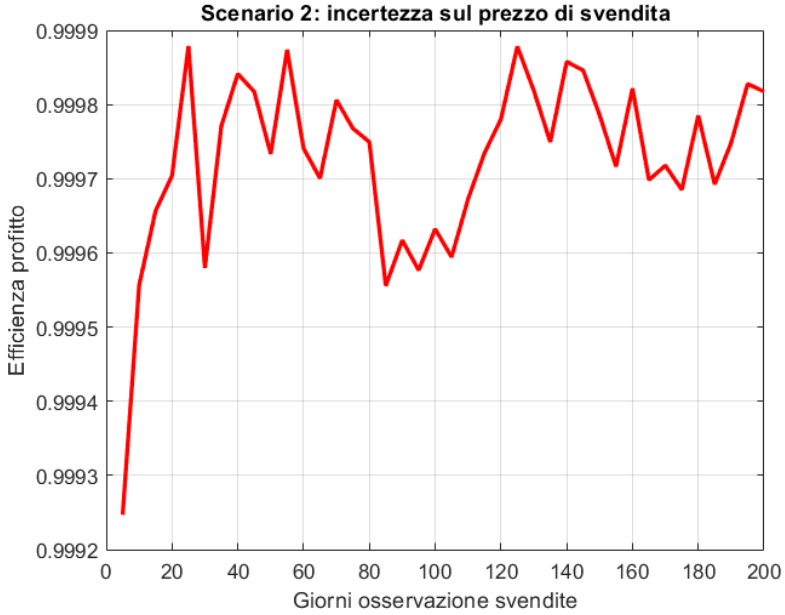


Figura 2: Impatto dell'errore di stima sui giorni di osservazione delle svendite.

Il grafico di questo secondo scenario ci racconta una storia diversa rispetto al precedente:

- **Partenza alta:** Come si evince dal grafico già con il set minimo di 5 giorni di osservazione l'efficienza del profitto si attesta su livelli superiori allo 0.98 (98%).Questo indica che, dati i nostri parametri di costo, il modello di stima è robusto e capace di garantire ottime performance quasi immediatamente e ci conferma come nel modello Newsvendor la corretta parametrizzazione della distribuzione della domanda costituisca l'elemento in assoluto più importante per avvicinarsi al profitto massimo teorico.
- **L'impatto del valore di recupero:** Nonostante la partenza alta, nei primissimi giorni di osservazione (sotto i 30 giorni) c'è ancora un margine di errore. Stimando in modo impreciso a quanto svenderemo la merce, calcoliamo male il rischio dell'invenduto (C_o) e commettiamo un piccolo errore nella quantità ordinata.
- **Stabilizzazione:** Aumentando i giorni di storico delle svendite verso i 200, il sistema apprende che in media recupereremo il 60% dei costi. La curva si appiattisce al

100%, confermando che conoscere bene il mercato dell'usato o dei saldi è necessario per massimizzare totalmente i guadagni.

In generale, il grafico evidenzia prestazioni eccezionalmente elevate (efficienza $> 99,9\%$) nonostante la carenza di dati su r. Avendo fatto diverse prove di simulazione, ci siamo rese conto che questo risultato non è un errore della simulazione, ma una proprietà analitica del modello: in contesti ad alto margine, la sensitività del profitto rispetto al prezzo di svendita è matematicamente trascurabile.

Isolando il parametro r attraverso la fissazione della domanda (μ e σ noti), abbiamo dimostrato che l'incertezza sui mercati secondari non rappresenta un rischio sistemico. Emerge quindi una netta differenza strutturale rispetto allo scenario 1: mentre la domanda è un parametro critico da cui dipende drasticamente il risultato economico, il prezzo di svendita rivela una resilienza tale da rendere quasi nullo l'impatto di un errore di stima. In un contesto reale, ci suggerisce di focalizzare le nostre risorve esclusivamente sulla previsione delle vendite principali.

4 Analisi dei risultati per il terzo scenario

4.1 Impostazione del problema

In questo terzo scenario l'obiettivo è analizzare come si comporta il modello quando i costi di sovrascorta e sottoscorta sono fortemente sbilanciati tra loro.

La scelta di condurre questo test fissando lo storico a 30 giorni nasce dai risultati dello scenario 1. Avendo dimostrato che sotto i 50 giorni le stime campionarie sono intrinsecamente imperfette, abbiamo utilizzato i 30 giorni come vero e proprio *stress test*. Il nostro obiettivo non è più quindi minimizzare l'errore, ma capire in che modo un'imprecisione di stima che è inevitabile in contesti operativi reali, si traduca in un danno economico al variare del rapporto tra i costi C_u e C_o, per avere una chiave di lettura utile a livello aziendale.

Sulla base di questo storico, abbiamo quindi analizzato cosa succede quando si cambia drasticamente il rapporto tra il costo delle mancate vendite (C_u) e il costo delle rimanenze (C_o). Per visualizzare questo sbilanciamento in modo chiaro, abbiamo usato una scala logaritmica sull'asse delle ascisse (asse x). In questo modo il grafico risulta visivamente simmetrico: il caso in cui C_u è 10 volte più grande di C_o e il caso inverso (in cui è 10 volte più piccolo) si trovano esattamente alla stessa distanza dal centro.

Nel codice, il processo logico seguito è il seguente:

1. Attraverso una routine dedicata, abbiamo fissato un campione storico ristretto per generare stime campionarie di media e varianza volutamente affette da incertezza statistica.
2. Abbiamo fatto variare dinamicamente i parametri di costo, alterando il rapporto C_u/C_o per esplorare l'intero spettro decisionale (da mercati a basso margine a mercati ad altissimo margine).
3. Infine, abbiamo calcolato le quantità ottime stimate e simulato le vendite, confrontando il profitto ottenuto con l'ottimo teorico per estrapolare l'efficienza ad ogni step logaritmico.

Questa impostazione ci permette di isolare il comportamento dell'algoritmo quando i pesi degli errori di stima (ordinare troppo rispetto a ordinare troppo poco) cambiano radicalmente.

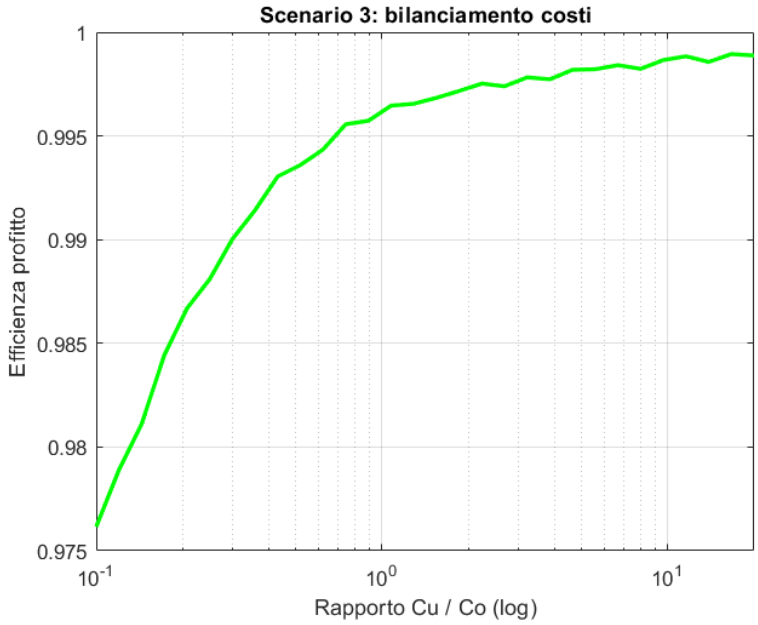


Figura 3: Degradazione del profitto in funzione del rapporto dei costi di penalità.

Dal grafico di questo terzo scenario si evince una asimmetria comportamentale:

- **Se l'invenduto costa caro ($c_o > c_u$):** Nella parte sinistra del grafico, l'efficienza crolla. Siccome le scorte in eccesso sono un grosso problema, i normali errori di stima (dovuti ai soli 30 giorni di dati storici) ci portano a sbagliare le quantità da ordinare, e i costi per smaltire la merce avanzata affossano i profitti.
- **Se perdere una vendita costa caro ($c_u > c_o$):** Spostandoci a destra, il modello regge molto bene. Quando i margini di guadagno sono alti, l'algoritmo preferisce ordinare quantità abbondanti pur di non rischiare di lasciare i clienti a mani vuote. In questa situazione, anche se sbagliamo a calcolare e ordiniamo troppa merce, l'impatto sull'utile finale è minimo. I soldi che facciamo riuscendo a coprire tutti i picchi di domanda imprevisti superano di gran lunga la perdita per i pezzi avanzati in magazzino.

5 Analisi dei risultati per il quarto scenario

5.1 Impostazione del problema

Nel quarto e ultimo scenario ci chiediamo cosa succede se il mercato è molto imprevedibile. Abbiamo misurato questa incertezza calcolando quanto varia la domanda rispetto alla sua media (il rapporto σ/μ), ma ci siamo fermati a un limite massimo di 0.30. Il motivo per cui abbiamo imposto tale limite è perché lavorando con una distribuzione normale, se alzassimo troppo la variabilità, il modello matematico inizierebbe a considerare

probabili anche vendite negative il che è ovviamente impossibile nella realtà, falsando completamente l'analisi.

Nel codice, abbiamo voluto testare come l'algoritmo gestisce questa turbolenza a seconda dei dati storici che ha a disposizione per fare le sue stime:

1. Abbiamo aumentato progressivamente la "turbolenza" della domanda (cioè la deviazione standard σ), lasciando fissa la media delle vendite (μ).
2. Abbiamo testato ogni livello di variabilità in due situazioni estreme: una in cui partiamo quasi alla cieca con soli 10 giorni di storico, e una in cui abbiamo un quadro solido con 250 giorni di dati.
3. Abbiamo poi simulato le vendite per confrontare la tenuta dei profitti nei due casi.

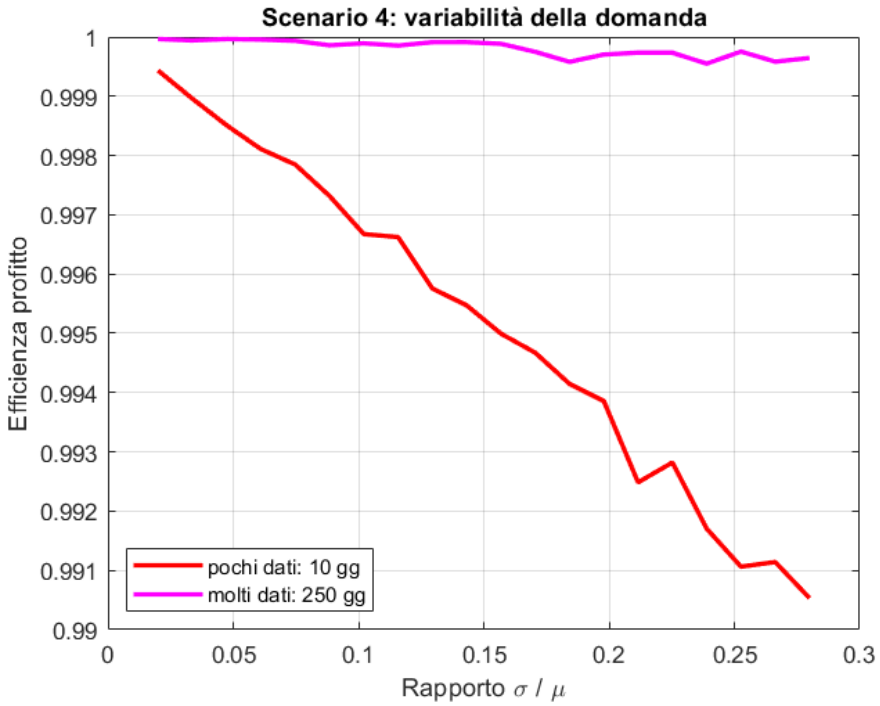


Figura 4: Efficienza del profitto all'aumentare del rapporto tra deviazione standard e valore atteso.

L'analisi del grafico permette di isolare l'impatto del rapporto σ/μ sulle performance, evidenziando che la sensibilità del profitto alla variabilità della domanda dipende drasticamente dalla profondità dello storico a disposizione. Nello specifico:

- **Impatto nullo con molti dati (250 giorni):** Se abbiamo uno storico solido, l'aumento del rapporto σ/μ non spaventa il modello. La curva superiore resta piatta, dimostrando che il sistema impara a gestire la volatilità e l'efficienza rimane vicina al 100%. Con i dati giusti, il modello Newsvendor è estremamente robusto anche in mercati molto volatili.
- **Impatto critico con pochi dati (10 giorni):** Qui vediamo il vero pericolo del rapporto σ/μ. Se lo storico è povero, ogni minimo aumento della variabilità fa

crollare l'efficienza in modo lineare. Senza dati sufficienti, l'algoritmo non riesce a distinguere tra un picco casuale e la reale struttura del mercato: i picchi di domanda ci coglieranno quindi impreparati e distruggono gran parte del profitto potenziale.

6 Caso aziendale: lancio di un nuovo smartwatch

Per dare un senso pratico a tutto quello che abbiamo simulato, abbiamo immaginato il caso di una multinazionale che deve lanciare un nuovo *smartwatch* poco prima di Natale. Abbiamo scelto questo prodotto perchè tendenzialmente nei periodi giusti, come le festività, si vende in poche settimane per poi lasciar posto a un nuovo articolo e quindi può essere modellizzato alla perfezione con il modello *Newsvedor* che gestisce scorte a singolo periodo. Inoltre, il margine di guadagno su ogni pezzo è molto alto rispetto a quanto costa produrlo ($c_u \gg c_o$).

Vediamo come applicare i risultati dei nostri quattro scenari al ciclo di vendita di tale oggetto:

1. **durata del test di vendita:** grazie agli scenari 1 e 4, sappiamo che un prodotto nuovo ha vendite molto imprevedibili. Lanciarlo alla cieca senza dati sarebbe quindi un disastro. Tuttavia, la nostra analisi ci dice che non serve aspettare mesi: dopo circa 30-40 giorni di test in una città pilota, le stime diventano già abbastanza stabili. All'azienda conviene quindi fare un test veloce e partire subito con il lancio globale, senza perdere tempo inutile a raccogliere dati che non migliorerebbero più di tanto il profitto.

2. **non concentrarsi sui saldi di fine stagione:** una volta passato Natale, gli orologi avanzati verranno svenduti. Lo scenario 2 ci ha dimostrato che non serve a nulla spendere soldi in algoritmi complicati per prevedere l'esatto prezzo di svendita r perchè anche se la stima su quanto recupereremo dai saldi è un po' imprecisa, il profitto finale non ne risente quasi per nulla. Molto meglio concentrare tutto l'impegno nel prevedere le vendite a prezzo pieno.

3. **la strategia che noi consigliamo è: meglio abbondare:** Lo scenario 3 fornisce le direttive per la vendita. Visto che guadagniamo molto su ogni vendita, perdere un cliente perché il prodotto è esaurito è è la criticità principale da evitare (c_u alto). Al contrario, avere qualche orologio in più in magazzino ci costa relativamente poco (c_o basso). La scelta logica è quindi quella di essere generosi con gli ordini: i guadagni che otterremo riuscendo a soddisfare ogni singolo cliente copriranno ampiamente il costo dei pochi pezzi che resteranno invenduti.

7 Conclusioni

In sintesi, la simulazione Monte Carlo ci ha permesso di quantificare come l'incertezza dei dati influenzi direttamente i profitti. Le risposte ai quesiti principali emersi dall'analisi sono:

- **Dimensione del campione:** ha un impatto critico nelle fasi iniziali. Pochi giorni di storico (sotto i 30) causano stime instabili e cali di efficienza. Superata questa soglia, però, il beneficio marginale di nuovi dati diminuisce: l'efficienza si stabilizza su un "plateau" e non serve uno storico infinito per ottenere ottime prestazioni.

- **Errore sul prezzo di svendita:** L'impatto è quasi trascurabile. Se la domanda principale è stimata correttamente, anche un errore significativo nella previsione del valore di recupero non sposta l'efficienza in modo rilevante. Le risorse analitiche vanno quindi concentrate sulla domanda, non sui saldi.
- **Rapporto tra costo di underage e di overage:** Il sistema è asimmetrico. È molto fragile quando l'invenduto costa più della mancata vendita ($c_o > c_u$), perché l'errore di stima genera eccedenze pesanti da smaltire. È invece molto resiliente quando i margini sono alti ($c_u > c_o$), poiché il guadagno copre i costi delle scorte extra.
- **Rapporto σ/μ:** In mercati molto instabili (σ/μ elevato), la mancanza di dati storici è catastrofica per il profitto. Al contrario, se lo storico è solido, il modello Newsvendor dimostra una grande robustezza, riuscendo ad assorbire la varianza senza perdite significative di efficienza.

In conclusione, il successo della gestione scorte non dipende dalla precisione assoluta su ogni parametro, ma dalla capacità di identificare dove l'incertezza pesa di più (volatilità della domanda e mercati a basso margine) e agire di conseguenza con politiche di scorta adeguate.